

第三章：凸优化基础

——优化论五部曲

Jason 博士

网易微专业 x 稀牛学院

人工智能数学基础微专业

一般优化问题

凸集和凸函数基础

凸优化问题

网易微专业 犀牛学院 人工智能数学基础 Jason博士

无约束优化问题

- 自变量为矢量的函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$\min f(\mathbf{x}) \quad \mathbf{x} \in \mathbb{R}^n$$

- 局部最优解常规解法
- 直接法
 - 梯度等于 0，求得驻点，必要时 Hessian 矩阵再进一步判断。
- 迭代法
 - 梯度下降法
 - 牛顿法
 - 拟牛顿法

一般约束优化问题

- 约束优化问题一般形式：


$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \text{ for } i = 1, 2, \dots, m \\ & && h_i(\mathbf{x}) = 0 \text{ for } i = 1, 2, \dots, p \end{aligned} \tag{1}$$

- 可行域：满足 $f(\mathbf{x})$ 定义域和约束条件的 \mathbf{x} 的集合。 $f_j(\mathbf{x}) = 0$ 表明不等式约束被激活 (active)。

一般约束优化问题 (举例)

- 考虑以下约束优化问题

$$\begin{aligned} & \text{minimize} && f(\mathbf{x}) = x_1^2 + x_2^2 - 4x_1 + 4 = (x_1 - 2)^2 + x_2^2 \\ & \text{subject to} && c_1(\mathbf{x}) = x_1 - 2x_2 + 6 \geq 0 \\ & && c_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \geq 0, c_3(\mathbf{x}) = x_1 \geq 0, c_4(\mathbf{x}) = x_2 \geq 0 \end{aligned}$$



补充知识 $A\mathbf{x} = \mathbf{b}$

矩阵乘法

$$\underbrace{\begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix}}_{\mathbf{A} \in \mathbb{R}^{2 \times 2}} \underbrace{\begin{bmatrix} x \\ y \end{bmatrix}}_{\mathbf{x} \in \mathbb{R}^2} = \underbrace{\begin{bmatrix} 1 \\ 5 \end{bmatrix}}_{\mathbf{b} \in \mathbb{R}^2} \quad (2)$$

$$\underbrace{\begin{bmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix}}_{\mathbf{A} \in \mathbb{R}^{3 \times 3}} \underbrace{\begin{bmatrix} u \\ v \\ w \end{bmatrix}}_{\mathbf{x} \in \mathbb{R}^3} = \underbrace{\begin{bmatrix} 5 \\ -2 \\ 9 \end{bmatrix}}_{\mathbf{b} \in \mathbb{R}^3} \quad (3)$$



$Ax = b$ 的行视图

- 行视图—超平面

$$2x - y = 1$$

$$x + y = 5$$

(4)



一般优化问题

凸集和凸函数基础

凸优化问题

网易微专业 犀牛学院 人工智能数学基础 Jason博士


为什么要凸优化?

- 思考：对于无约束优化问题，梯度等于 0 这一条件是否可以成为充要条件？
- 思考：什么样的情况局部最小解可以成为全局最小解？
- 思考：约束优化问题怎么办？（下次课）
- 思考：研究凸优化问题对于非凸问题又有什么帮助？（下次课）


凸集 (Convex Sets)(Solid, no holes, and curve outward)

仿射集 (Affine Sets) 和凸集

- 如果一个集合 $C \in \mathbb{R}^n$ 是仿射的，则 C 中两点间的直线也在 C 中，例如 $\mathbf{x} = \theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2 \in C, \theta \in \mathbb{R}$ ，即 $\mathbf{Ax} = \mathbf{b}$ 的解



- 一个集合 $C \in \mathbb{R}^n$ 是凸的，则对于任意的 $\mathbf{x}, \mathbf{y} \in C$ ，有 $\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in C, 0 \leq \theta \leq 1$




常见的凸集 (1/3)

- 所有 \mathbb{R}^n , 给定任意 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 则有 $\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in \mathbb{R}^n$
- 所有 \mathbb{R}_+^n
- 超平面 (Hyperplane): 既是仿射又是凸

$$C = \{\mathbf{x} \mid \mathbf{a}^T \mathbf{x} = b\}$$

- 半空间 (Halfspace): 只是凸



向量范数 (补充知识)

- 2-norm:

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = (\mathbf{x}^T \mathbf{x})^{1/2}$$

- 1-norm:

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

- ∞ -norm:


$$\|\mathbf{x}\|_\infty = \max_{i=1, \dots, n} |x_i|$$

- p -norm, $p \geq 1$:


$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}.$$

常见的凸集 (2/3)

- 范数球，例如 $\|\mathbf{x}\|_2 \leq 1$. 给定任意 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 且 $\|\mathbf{x}\|_2 \leq 1, \|\mathbf{y}\|_2 \leq 1$ ，则有 $\|\theta\mathbf{x} + (1 - \theta)\mathbf{y}\|_2 \leq \theta\|\mathbf{x}\|_2 + (1 - \theta)\|\mathbf{y}\|_2 \leq 1$



(a) Region of $\|x\|_p = 1, p \geq 1$.



(b) Region of $\|x\|_p = 1, p \leq 1$.

凸集的性质

- **凸集的交集是凸集**，例如： $S = \{\|\mathbf{x}\| \leq 1, \mathbf{x} \geq \mathbf{0}\}$
- 证明：假定 S_1, \dots, S_k 是凸集，给定 $\mathbf{x}, \mathbf{y} \in \cap_{i=1}^k S_i$ ，则有

$$\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in S_i, \quad i = 1, \dots, k$$

因此，

$$\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in \cap_{i=1}^k S_i$$


- 注意：凸集的并集不一定是凸集

常见的凸集 (3/3)

- 多面体 (Polyhedron): 有限个半空间和半平面的交集

$$\mathcal{P} = \{\mathbf{x} \mid \mathbf{Ax} \leq \mathbf{b}, \mathbf{Cx} = \mathbf{d}\}$$

其中 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$, $\mathbf{C} \in \mathbb{R}^{p \times n}$, $\mathbf{d} \in \mathbb{R}^p$




凸函数

- 一个函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 被称为凸函数，如果

- 1 $\text{dom}(f)$ (f 的定义域) 是凸集
- 2 对于任何 $\mathbf{x}, \mathbf{y} \in \text{dom}(f)$ 和 $0 \leq \theta \leq 1$, 有

$$f(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) \leq \theta f(\mathbf{x}) + (1 - \theta) f(\mathbf{y})$$


- 几何解释



凸函数的一阶二阶条件

- 一阶充要条件 (不好用): $f(\mathbf{x}_1) \geq f(\mathbf{x}) + \nabla^T f(\mathbf{x})(\mathbf{x}_1 - \mathbf{x})$ 对于所有 \mathbf{x}_1, \mathbf{x} 均成立. 作业: 证明凸函数局部最优解就是全局最优解 (提示: 用凸函数定义)
- 二阶充要条件 (好用): 如果函数 f 二阶可导, 则凸函数充要条件:


$$\mathbf{H}(\mathbf{x}) \succeq \mathbf{0}$$



常见的凸函数 (1/2)

一元函数举例



- $ax + b$ convex and also concave
- x^2 convex
- $e^{\alpha x}$ convex
- $-\log x$ convex on $x > 0$
- $x \log x$ convex on $x \geq 0$




常见的凸函数 (2/2)

二元函数举例

- $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + \mathbf{b}$ convex and also concave
- $f(\mathbf{x}) = \mathbf{x}^T \mathbf{P} \mathbf{x} + 2\mathbf{q}^T \mathbf{x} + \mathbf{r}$ 是 convex 当且仅当 $\mathbf{P} \succeq \mathbf{0}$
 $f(\mathbf{x}) = \|\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{x}$



(a) $\mathbf{P} \succeq \mathbf{0}$.



(b) $\mathbf{P} \not\succeq \mathbf{0}$.

保凸运算

保凸

- f 凸, 则 $f(\mathbf{Ax} + \mathbf{b})$ 凸, 例如 $\|\mathbf{y} - \mathbf{Ax}\|_2$
- g 凸, h 凸, 扩展的 h 非递减, 则 $f(\mathbf{x}) = h(g(\mathbf{x}))$ 凸. 例如 $f(\mathbf{x}) = \|\mathbf{y} - \mathbf{Ax}\|_2^2$ 凸, $g(\mathbf{x}) = \|\mathbf{y} - \mathbf{Ax}\|_2, h(x) = x^2$ 在 $x \geq 0$ 的部分非递减.
- f_1, \dots, f_m 凸, $w_1, \dots, w_m \geq 0$, 则 $\sum_{i=1}^m w_i f_i$ 凸. 例如 $f(\mathbf{x}) = \|\mathbf{y} - \mathbf{Ax}\|_2^2 + \gamma \|\mathbf{x}\|_2^2$ 凸, $\gamma \geq 0$
- 逐点最大: f_1, \dots, f_m 凸, 则 $f(\mathbf{x}) = \max \{f_1(\mathbf{x}), \dots, f_m(\mathbf{x})\}$ 凸. $f(\mathbf{x}, \mathbf{y})$ 对于每个 $\mathbf{y} \in \mathcal{A}$ 凸, 则 $\sup_{\mathbf{y} \in \mathcal{A}} f(\mathbf{x}, \mathbf{y})$ 凸.


凸函数和凸集的关系

α 水平集 (sublevel set)


- 一元函数 f 的 α 水平集为

$$S_\alpha = \{x \mid f(x) \leq \alpha\}$$

- 则有 f 凸函数 $\Rightarrow S_\alpha$ 对于每个 α 是凸集, 反之不成立.



convex f and convex S_α



non-convex f but convex S_α

一般优化问题

凸集和凸函数基础

凸优化问题

网易微专业 犀牛学院 人工智能数学基础 Jason博士

凸优化问题标准形式 (Game Over)

- 凸优化问题

$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \text{ for } i = 1, 2, \dots, m \\ & && h_i(\mathbf{x}) = 0 \text{ for } i = 1, 2, \dots, p \end{aligned} \tag{5}$$

- 则有 $f_0(\mathbf{x})$ 是凸函数，可行域是凸集

- 目标函数是凸的
- 不等式约束函数必须是凸的
- 等式约束函数必须是仿射的

- 在一个凸集上极小化一个凸的目标函数

- 最优值 (目标函数在可行域上的最小值):

$$p^* = \min \{f_0(\mathbf{x}) : f_i(\mathbf{x}) \leq 0, h_i(\mathbf{x}) = 0\}$$

- $p^* = +\infty$ 不可行 (可行域是空集)
- $p^* = -\infty$, unbounded below (存在可行点使得 $f_0(x) \rightarrow -\infty$)
- $f_0(\mathbf{x}^*) = p^*$

凸优化问题的重要结论

凸优化问题局部最优 = 全局最优

- 局部最优 \mathbf{x} , 存在 $R > 0$, 对于所有可行点 \mathbf{z} , 且有 $\|\mathbf{x} - \mathbf{z}\|_2 \leq R$, 满足 $f_0(\mathbf{x}) \leq f_0(\mathbf{z})$
- 全局最优 \mathbf{x} , 对所有可行点 \mathbf{z} , 有 $f_0(\mathbf{x}) \leq f_0(\mathbf{z})$
- 反证法: 作业
- 特别对于无约束问题
 - 梯度等于 0
 - 迭代法

典型的凸优化问题

- 线性规划 (Linear Programming)

$$\begin{aligned} & \text{minimize} && \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & && \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{6}$$

- 二次规划 (Quadratic Programming)(\mathbf{P} 半正定)

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & && \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{7}$$

- QCQP(\mathbf{P} 和 \mathbf{Q}_i 均半正定)

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \frac{1}{2} \mathbf{x}^T \mathbf{Q}_i \mathbf{x} + \mathbf{r}_i^T \mathbf{x} + s_i \leq 0, \quad i = 1, \dots, m, \quad \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

案例 1：凸优化问题转成标准型

- 给定下列问题

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \xi_i \\ & \text{subject to} && y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, m \\ & && \xi_i \geq 0 \end{aligned} \tag{8}$$

其中 $\mathbf{w} \in \mathbb{R}^n, \boldsymbol{\xi} = [\xi_1, \dots, \xi_m]^T \in \mathbb{R}^m, b \in \mathbb{R}$. 定义 $k = m + n + 1$

- 变量

$$\mathbf{x} \in \mathbb{R}^k = \begin{bmatrix} \mathbf{w} \\ \boldsymbol{\xi} \\ b \end{bmatrix}$$

- 定义 $\mathbf{X} \in \mathbb{R}^{m \times n} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}, \mathbf{y} \in \mathbb{R}^m = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$

案例 1: 凸优化问题转成标准型

- QP

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \mathbf{G} \mathbf{x} \leq \mathbf{h} \\ & && \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned} \tag{9}$$

- 定义

$$\mathbf{P} \in \mathbb{R}^{k \times k} = \begin{bmatrix} \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \mathbf{c} \in \mathbb{R}^k = \begin{bmatrix} 0 \\ C \cdot \mathbf{1} \\ 0 \end{bmatrix}$$

$$\mathbf{G} \in \mathbb{R}^{2m \times k} = \begin{bmatrix} -\text{diag}(\mathbf{y}) \mathbf{X} & -\mathbf{I} & -\mathbf{y} \\ 0 & -\mathbf{I} & 0 \end{bmatrix}, \mathbf{h} \in \mathbb{R}^{2m} = \begin{bmatrix} -\mathbf{1} \\ 0 \end{bmatrix}$$

案例 2: CVX 演示

网易微专业 犀牛学院 人工智能数学基础 Jason博士

本章总结

网易微专业 犀牛学院 人工智能数学基础 Jason博士

本章参考资料

Boyd, Stephen, and Lieven Vandenberghe. Convex optimization. Cambridge university press, 2004.