

第四章：凸优化进阶之对偶理论

——优化论五部曲

Jason 博士

网易微专业 × 稀牛学院

人工智能数学基础微专业

凸优化问题标准形式

- 凸优化问题

$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \text{ for } i = 1, 2, \dots, m \\ & && h_i(\mathbf{x}) = 0 \text{ for } i = 1, 2, \dots, p \end{aligned} \tag{1}$$

- 则有 $f_0(\mathbf{x})$ 是凸函数，可行域是凸集

- 目标函数是凸的
- 不等式约束函数必须是凸的
- 等式约束函数必须是仿射的

- 在一个凸集上极小化一个凸的目标函数

- 最优值 (目标函数在可行域上的最小值):

$$p^* = \min \{f_0(\mathbf{x}) : f_i(\mathbf{x}) \leq 0, h_i(\mathbf{x}) = 0\}$$

- $p^* = +\infty$ 不可行 (可行域是空集)
- $p^* = -\infty$, unbounded below (存在可行点使得 $f_0(x) \rightarrow -\infty$)
- $f_0(\mathbf{x}^*) = p^*$

无约束凸优化问题

- 自变量为矢量的函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$


$$\min f(\mathbf{x}) \quad \mathbf{x} \in \mathbb{R}^n$$

- 全局最优解常规解法
- 直接法
 - 梯度等于 0，求得驻点
- 迭代法
 - 梯度下降法
 - 牛顿法
 - 拟牛顿法

有约束凸优化问题

- 考虑以下约束优化问题

$$\begin{aligned} & \text{minimize} && f(\mathbf{x}) = x_1^2 + x_2^2 - 4x_1 + 4 = (x_1 - 2)^2 + x_2^2 \\ & \text{subject to} && c_1(\mathbf{x}) = x_1 - 2x_2 + 6 \geq 0 \\ & && c_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \geq 0, c_3(\mathbf{x}) = x_1 \geq 0, c_4(\mathbf{x}) = x_2 \geq 0 \end{aligned}$$



凸优化问题

对偶

问题案例

网易微专业 犀牛学院 人工智能数学基础 Jason博士

一般优化问题

$$\begin{array}{ll}\text{minimize} & f_0(\mathbf{x}) \\ \text{subject to} & f_i(\mathbf{x}) \leq 0 \text{ for } i = 1, 2, \dots, m \\ & h_i(\mathbf{x}) = 0 \text{ for } i = 1, 2, \dots, p\end{array}\quad (2)$$

问题定义域 $\mathcal{D} = (\cap_{i=1}^m \text{dom } f_i) \cap (\cap_{i=1}^p \text{dom } h_i)$ ，注意与可行域区分。

Lagrangian(合并目标函数和约束)

- Lagrangian

$$L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x})$$

- 主变量: \mathbf{x}
- 对偶变量: $\boldsymbol{\lambda} \geq 0, \mathbf{v}$
- 意义解释

主问题

- Lagrangian

$$L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x})$$

- 主问题

$$p^* = \min_{\mathbf{x}} \left(\max_{\boldsymbol{\lambda}, \mathbf{v}} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) \right)$$

- 分开看

$$\max_{\boldsymbol{\lambda}, \mathbf{v}} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}) + \max_{\boldsymbol{\lambda}, \mathbf{v}} \left(\sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x}) \right)$$

对偶

Lagrange 对偶函数

- Lagrangian

$$g(\boldsymbol{\lambda}, \boldsymbol{v}) = \min_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{v}) = \min_{\mathbf{x} \in \mathcal{D}} \left\{ f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x}) \right\}$$

- 回忆：逐点最大： f_1, \dots, f_m 凸，则 $f(\mathbf{x}) = \max \{f_1(\mathbf{x}), \dots, f_m(\mathbf{x})\}$ 凸。
 $f(\mathbf{x}, \mathbf{y})$ 对于每个 $\mathbf{y} \in \mathcal{A}$ 凸，则 $\max_{\mathbf{y} \in \mathcal{A}} f(\mathbf{x}, \mathbf{y})$ 凸。 g 是 $(\boldsymbol{\lambda}, \boldsymbol{v})$ 的仿射函数的逐点下确界 (min)，总是凹的，即使原问题非凸。

对偶

Lagrange 对偶函数

- Lagrangian

$$g(\boldsymbol{\lambda}, \boldsymbol{v}) = \min_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{v}) = \min_{\mathbf{x} \in \mathcal{D}} \left\{ f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x}) \right\}$$

- 如果 $\tilde{\mathbf{x}}$ 是一个可行点, 则

$$g(\boldsymbol{\lambda}, \boldsymbol{v}) = \min_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{v}) \leq L(\tilde{\mathbf{x}}, \boldsymbol{\lambda}, \boldsymbol{v})$$

$$L(\tilde{\mathbf{x}}, \boldsymbol{\lambda}, \boldsymbol{v}) = f_0(\tilde{\mathbf{x}}) + \sum_{i=1}^m \lambda_i f_i(\tilde{\mathbf{x}}) + \sum_{i=1}^p v_i h_i(\tilde{\mathbf{x}}) \leq f_0(\tilde{\mathbf{x}})$$

- 因此 $g(\boldsymbol{\lambda}, \boldsymbol{v}) \leq f_0(\mathbf{x}^*) = p^*$

Lagrange 对偶问题

Lagrange 对偶问题



- Lagrange 对偶问题

$$\begin{array}{ll}\text{maximize} & g(\boldsymbol{\lambda}, v) \\ \text{subject to} & \boldsymbol{\lambda} \geq \mathbf{0}\end{array}$$

- 目标函数: $\max_{\boldsymbol{\lambda} \geq \mathbf{0}, v} \min_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, v)$
- 凹函数在凸集上最大化, 这是一凸优化问题, 设最优值为 d^* , 对应的极值点是 $\boldsymbol{\lambda}^*, v^*$

对偶几何解释

- $L(\mathbf{x}, \boldsymbol{\lambda}) = f_0(\mathbf{x}) + \lambda f_1(\mathbf{x})$



强弱对偶解释

- 弱对偶: $d^* \leq p^*$, 无论凸或非凸问题总成立
- 强对偶: $d^* = p^*$
 - 该条件通常不成立
 - 对于凸优化问题通常 (usually) 成立
 - 凸优化问题可以写为

$$\begin{array}{ll}\text{minimize} & f_0(\mathbf{x}) \\ \text{subject to} & f_i(\mathbf{x}) \leq 0 \text{ for } i = 1, 2, \dots, m \\ & \mathbf{Ax} = \mathbf{b}\end{array}$$

- 满足 Slater 条件 (constraint qualifications): 存在内点 \mathbf{x} , 使得 $f_i(\mathbf{x}) < 0$ for $i = 1, 2, \dots, m$ 均成立

从对偶问题解主问题

- 假定强对偶成立, $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \mathbf{v}^*)$ 是主对最优解, 有

$$\begin{aligned} p^* &= f_0(\mathbf{x}^*) = d^* = g(\boldsymbol{\lambda}^*, \mathbf{v}^*) \\ &= \min_{\mathbf{x}} \left(f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i^* f_i(\mathbf{x}) + \sum_{i=1}^p v_i^* h_i(\mathbf{x}) \right) \\ &\leq f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* f_i(\mathbf{x}^*) + \sum_{i=1}^p v_i^* h_i(\mathbf{x}^*) \\ &\leq f_0(\mathbf{x}^*) \end{aligned}$$

- 结论 1: $\lambda_i^* f_i(\mathbf{x}^*) = 0$
- 结论 2: $L(\mathbf{x}, \boldsymbol{\lambda}^*, \mathbf{v}^*)$ 关于 \mathbf{x}^* 处取极小值, 有 $\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \mathbf{v}^*) = \mathbf{0}$
 - $g(\boldsymbol{\lambda}^*, \mathbf{v}^*) = L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \mathbf{v}^*)$
 - $g(\boldsymbol{\lambda}^*, \mathbf{v}^*) = \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}^*, \mathbf{v}^*)$

KKT 条件

- 凸优化问题

$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \text{ for } i = 1, 2, \dots, m \\ & && h_i(\mathbf{x}) = 0 \text{ for } i = 1, 2, \dots, p \end{aligned}$$

- Lagrangian

$$L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x})$$

凸优化问题强对偶成立，充要条件

- $f_i(\mathbf{x}^*) \leq 0, i = 1, \dots, m$ ($\nabla_{\boldsymbol{\lambda}} L(\mathbf{x}^*, \boldsymbol{\lambda}, \mathbf{v}) \leq \mathbf{0}$)
- $h_i(\mathbf{x}^*) = 0, i = 1, \dots, p$ ($\nabla_{\mathbf{v}} L(\mathbf{x}^*, \boldsymbol{\lambda}, \mathbf{v}) = \mathbf{0}$)
- $\lambda_i^* \geq 0, i = 1, \dots, m$
- $\lambda_i^* f_i(\mathbf{x}^*) = 0, i = 1, \dots, m$
- $\nabla f_0(\mathbf{x}^*) + \sum_i \lambda_i^* \nabla f_i(\mathbf{x}^*) + \sum_i v_i^* \nabla h_i(\mathbf{x}^*) = \mathbf{0}$ ($\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \mathbf{v}^*) = \mathbf{0}$)

KKT 条件

- 非凸问题弱对偶，KKT 局部极小解的一阶必要条件
- 求解 KKT
- 在某些情况下可以得到闭合解
- 求解凸优化问题方法可以认为求解 KKT

主对问题思考

- 主问题

$$p^* = \min_{\mathbf{x}} \left(\max_{\lambda \geq 0, v} L(\mathbf{x}, \lambda, v) \right)$$

- 对偶问题

$$d^* = \max_{\lambda \geq 0, v} \left(\min_{\mathbf{x}} L(\mathbf{x}, \lambda, v) \right)$$

主对关系（强对偶成立 $\max \min$ 可以交换）

$$\max_{\lambda \geq 0, v} \left(\min_{\mathbf{x}} L(\mathbf{x}, \lambda, v) \right) \leq \min_{\mathbf{x}} \left(\max_{\lambda \geq 0, v} L(\mathbf{x}, \lambda, v) \right)$$

凸优化问题

对偶

问题案例

网易微专业 犀牛学院 人工智能数学基础 Jason博士

最小 2 范数解问题

- 求解下列问题

$$p^* = \min_{\mathbf{x}} \|\mathbf{x}\|_2^2$$
$$s.t. \mathbf{Ax} = \mathbf{b}$$

- Lagrangian

$$L(\mathbf{x}, \mathbf{v}) = \mathbf{x}^T \mathbf{x} + \mathbf{v}^T (\mathbf{Ax} - \mathbf{b})$$

- 对偶函数

$$g(\mathbf{v}) = \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{v})$$

- $\nabla_{\mathbf{x}} L(\mathbf{x}, \mathbf{v}) = \mathbf{0} \Rightarrow 2\mathbf{x} + \mathbf{A}^T \mathbf{v} = \mathbf{0} \Rightarrow \mathbf{x}^*(\mathbf{v}) = -\frac{1}{2} \mathbf{A}^T \mathbf{v}$
- $g(\mathbf{v}) = L(\mathbf{x}^*(\mathbf{v}), \mathbf{v}) = -\frac{1}{4} \mathbf{v}^T (\mathbf{AA}^T) \mathbf{v} - \mathbf{v}^T \mathbf{b}$

最小 2 范数解问题

- 对偶问题

$$d^* = \max_{\mathbf{v}} -\frac{1}{4} \mathbf{v}^T (\mathbf{A} \mathbf{A}^T) \mathbf{v} - \mathbf{v}^T \mathbf{b}$$

- 可求得

$$\mathbf{v}^* = -2 (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

$$d^* = \mathbf{b}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

- 由于 $p^* = d^*$, 则

$$\mathbf{x}^* = \mathbf{x}^* (\mathbf{v}^*) = \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

- Lower bound

$$p^* \geq -\frac{1}{4} \mathbf{v}^T (\mathbf{A} \mathbf{A}^T) \mathbf{v} - \mathbf{v}^T \mathbf{b} \quad \text{for all } \mathbf{v}$$

SVM 前奏

LP

- 求解下列问题

$$\begin{aligned} p^* &= \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \\ s.t. \quad &\mathbf{Ax} \leq \mathbf{b} \end{aligned}$$

- Lagrangian

$$L(\mathbf{x}, \boldsymbol{\lambda}) = \mathbf{c}^T \mathbf{x} + \boldsymbol{\lambda}^T (\mathbf{Ax} - \mathbf{b}) = -\mathbf{b}^T \boldsymbol{\lambda} + (\mathbf{A}^T \boldsymbol{\lambda} + \mathbf{c})^T \mathbf{x}$$

- 对偶函数

$$g(\boldsymbol{\lambda}) = \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}) = -\mathbf{b}^T \boldsymbol{\lambda} + \min_{\mathbf{x}} (\mathbf{A}^T \boldsymbol{\lambda} + \mathbf{c})^T \mathbf{x}$$

SVM 前奏

LP

- 可以发现

$$g(\boldsymbol{\lambda}) = \begin{cases} -\mathbf{b}^T \boldsymbol{\lambda} & \mathbf{A}^T \boldsymbol{\lambda} + \mathbf{c} = \mathbf{0} \\ -\infty & \text{others} \end{cases}$$

- 对偶问题

$$\begin{aligned} d^* &= \max_{\boldsymbol{\lambda}} -\mathbf{b}^T \boldsymbol{\lambda} \\ \text{s.t. } & \mathbf{A}^T \boldsymbol{\lambda} + \mathbf{c} = \mathbf{0} \\ & \boldsymbol{\lambda} \geq \mathbf{0} \end{aligned}$$

- 对偶的对偶

本章总结

网易微专业 犀牛学院 人工智能数学基础 Jason博士

本章参考资料

- Boyd, Stephen, and Lieven Vandenberghe. Convex optimization. Cambridge university press, 2004.
- Goodfellow, Ian, Yoshua Bengio, and Aaron Courville. Deep learning. MIT press, 2016.