

# 第五章：SVM

## ——优化论五部曲

Jason 博士

网易微专业 x 稀牛学院

人工智能数学基础微专业

## 机器学习中两种问题

SVM 建模

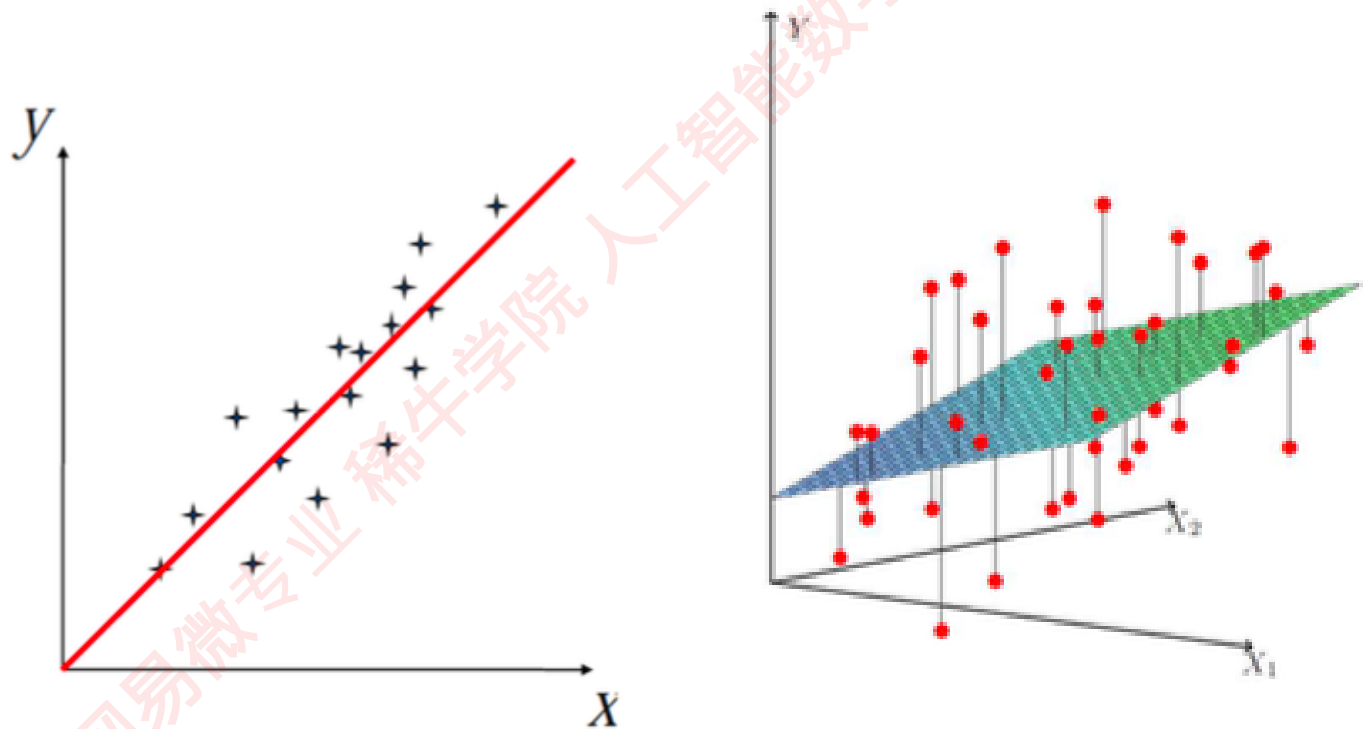
SVM 求解

SVM 扩展

网易微专业 犀牛学院 人工智能数学基础 Jason博士


# 回归

- 给定训练样本集  $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ ,  $\mathbf{x}_i \in \mathbb{R}^d$
- 回归：预测的是连续值



# 分类

- 给定训练样本集  $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ ,  $\mathbf{x}_i \in \mathbb{R}^d$
- 分类：预测的是离散值
- 二分类：  $y_i \in \{-1, +1\}$



机器学习中两种问题

SVM 建模

SVM 求解


SVM 扩展

网易微专业 犀牛学院 人工智能数学基础 Jason博士

# SVM 的发明

## Vladimir Vapnik

- Ph.D. in Statistics 1964
- Ins. Control Sci. Moscow 1964-1990 AT&T, USA 1990 2002 (developed Support Vector Machines)
- NEC Laboratories 2002-now
- U.S. National Academy of Engineering 2006




# 线性分类器和最优线性分类器

- 样本空间中，切分超平面

$$\mathbf{w}^T \mathbf{x} + b = 0$$

- $\mathbf{w}$  法向量,  $b$  偏移



# 点到超平面的距离

- 超平面  $H = \{\mathbf{w}^T \mathbf{x} + b = 0\}$
- 空间中任意一点  $\mathbf{p}$  到平面的距离为

$$r = \frac{|\mathbf{w}^T \mathbf{p} + b|}{\|\mathbf{w}\|_2}$$

- 课堂推导证明




# SVM 目标函数

- 几何间隔 (Geometric margin):

$$M = \min_i r_i = \min_i \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|_2}$$

- SVM 目标函数

$$\max_{\mathbf{w}, b} M$$
$$\max_{\mathbf{w}, b} \left\{ \min_i \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|_2} \right\}$$



# 简化目标函数

- 1 分子部分  $|\mathbf{w}^T \mathbf{x}_i + b|$  改写为

$$y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

- 2 目标函数由  $\max_{\mathbf{w}, b} \left\{ \min_i \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|_2} \right\}$  变为

$$\max_{\mathbf{w}, b} \left\{ \min_i \frac{y_i (\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|_2} \right\}$$

$$\max_{\mathbf{w}, b} \left\{ \frac{1}{\|\mathbf{w}\|_2} \min_i y_i (\mathbf{w}^T \mathbf{x}_i + b) \right\}$$

# 简化目标函数

## Rescaling

- 目标函数

$$\max_{\mathbf{w}, b} \left\{ \frac{1}{\|\mathbf{w}\|_2} \min_i y_i (\mathbf{w}^T \mathbf{x}_i + b) \right\}$$

- Rescaling  $\mathbf{w} \rightarrow k\mathbf{w}$  和  $b \rightarrow kb$ , 点到超平面距离不变.
- 因此可以设计距离最近的一个点, 使得

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) = 1$$

- 同时有


$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, \dots, N$$

# 简化 SVM 目标函数

## - SVM 基本型

$$\begin{aligned} \min \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{subject to} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, N \end{aligned}$$

## - 几何解释



机器学习中两种问题

SVM 建模

SVM 求解

SVM 扩展

网易微专业 犀牛学院 人工智能数学基础 Jason博士

# QP 问题

## - QP 标准型

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \mathbf{G} \mathbf{x} \leq \mathbf{h} \\ & && \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned} \tag{1}$$

## - QP 问题

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i \\ & \text{subject to} && y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, N \\ & && \xi_i \geq 0 \end{aligned} \tag{2}$$

# 转成标准型

- 定义

$$\mathbf{x} \in \mathbb{R}^k = \begin{bmatrix} \mathbf{w} \\ \boldsymbol{\xi} \\ b \end{bmatrix}$$

- 定义

$$\mathbf{P} \in \mathbb{R}^{k \times k} = \begin{bmatrix} \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \mathbf{c} \in \mathbb{R}^k = \begin{bmatrix} 0 \\ C \cdot \mathbf{1} \\ 0 \end{bmatrix}$$

$$\mathbf{G} \in \mathbb{R}^{2N \times k} = \begin{bmatrix} -\text{diag}(\mathbf{y}) \mathbf{X} & -\mathbf{I} & -\mathbf{y} \\ 0 & -\mathbf{I} & 0 \end{bmatrix}, \mathbf{h} \in \mathbb{R}^{2N} = \begin{bmatrix} -\mathbf{1} \\ 0 \end{bmatrix}$$

# SVM 对偶问题

- Lagrangian 函数

$$L(\mathbf{w}, b, \boldsymbol{\lambda}) = \frac{1}{2} \|\mathbf{w}\|_2^2 + \sum_{i=1}^N \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b))$$

- 回忆对偶问题

$$d^* = \max_{\boldsymbol{\lambda} \geq 0} \left( \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\lambda}) \right)$$

- 令  $L(\mathbf{w}, b, \boldsymbol{\lambda})$  对  $\mathbf{w}$  和  $b$  的偏导为 0, 则有  $\mathbf{w} = \sum_{i=1}^N \lambda_i y_i \mathbf{x}_i$  和  $0 = \sum_{i=1}^N \lambda_i y_i$

- 代入则有

$$\begin{aligned} \max_{\boldsymbol{\lambda}} \quad & \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{subject to} \quad & \sum_{i=1}^N \lambda_i y_i = 0, \lambda_i \geq 0, i = 1, \dots, N \end{aligned}$$



- 假定能够解出  $\lambda^*$ ，强对偶，根据 KKT 有

- $y_i (\mathbf{w}^{*T} \mathbf{x}_i + b^*) \geq 1$
- $\lambda_i^* \geq 0$
- $\lambda_i^* (y_i (\mathbf{w}^{*T} \mathbf{x}_i + b^*) - 1) = 0$
- $\mathbf{w}^* = \sum_{i=1}^N \lambda_i^* y_i \mathbf{x}_i, \sum_{i=1}^N \lambda_i^* y_i = 0$

解释

- 若  $\lambda_j^* = 0$ ，对  $\mathbf{w}^*$  毫无贡献
- 若  $\lambda_j^* > 0$ ，则  $y_j (\mathbf{w}^{*T} \mathbf{x}_j + b^*) = 1$ ，为支撑向量。
- $\mathbf{w}^* = \sum_{i=1}^N \lambda_i^* y_i \mathbf{x}_i$  代入  $y_j (\mathbf{w}^{*T} \mathbf{x}_j + b^*) = 1$ ，则  $b^* = y_j - \sum_{i=1}^N \lambda_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j)$

# SVM 最终步骤

- 最优分离超平面

$$\mathbf{w}^{*T} \mathbf{x} + b^* = 0$$

$$\sum_{i=1}^N \lambda_i^* y_i \mathbf{x}_i \mathbf{x} + b^* = 0$$

- 决策函数

$$f(\mathbf{x}) = \text{sign} \left( \sum_{i=1}^N \lambda_i^* y_i \mathbf{x}_i \mathbf{x} + b^* \right)$$

# SMO 求解 $\lambda^*$ [Platt, 1998]

## 思想

- 求解下列无约束优化问题

$$\max_{\lambda} W(\lambda_1, \lambda_2, \dots, \lambda_m)$$

- 除了之前谈到的算法，还可以考虑这样解：例如固定  $\lambda_2, \dots, \lambda_m$ ，求解  $\lambda_1$ ，反复迭代。
- SVM 中不能只留一个变量，因为  $\sum_{i=1}^N \lambda_i y_i = 0$ .
  - 选取一对需要更新的变量  $\lambda_i$  和  $\lambda_j$
  - 固定其它参数，求解 SVM 对偶式，得  $\lambda_i$  和  $\lambda_j$
  - 每次求解是关于  $\lambda_i$  的单变量 QP 问题，仅有的约束是  $\lambda_i \geq 0$ ，一维搜索问题<sup>a</sup>。

---

<sup>a</sup>Platt, J. (1998). "Sequential minimal optimization: A fast algorithm for training support vector machines." Technical Report MSR-TR-98-14, Microsoft Research

机器学习中两种问题

SVM 建模

SVM 求解


SVM 扩展

网易微专业 犀牛学院 人工智能数学基础 Jason博士

# 软间隔

## - SVM 软间隔

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i \\ & \text{subject to} && y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, N \\ & && \xi_i \geq 0 \end{aligned}$$




# 核函数 (1/3)

## 思想

- 线性不可分时?
- 特征映射  $\mathbf{x} \mapsto \phi(\mathbf{x})$
- SVM 目标函数

$$\begin{aligned} \min \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{subject to} \quad & y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, \dots, N \end{aligned}$$



## 核函数 (2/3)

- 特征映射  $\mathbf{x} \mapsto \phi(\mathbf{x})$ , 对偶问题

$$\begin{aligned} \max_{\lambda} \quad & \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \\ \text{subject to} \quad & \sum_{i=1}^N \lambda_i y_i = 0, \lambda_i \geq 0, i = 1, \dots, N \end{aligned}$$

- 直接计算  $\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$  很困难, 假设有如下函数 (核技巧)

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

- 决策函数

$$f(\mathbf{x}) = \text{sign} \left( \sum_{i=1}^N \lambda_i^* y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b^* \right)$$

# 核函数 (3/3)

## 常用核函数

- 线性核

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$$

- 多项式核

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d, d \geq 1$$

- 高斯核

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$

- 拉普拉斯核

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|}{\sigma}\right)$$

- Sigmoid 核

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$$



# SVM 案例演示

网易微专业 犀牛学院 人工智能数学基础 Jason博士

# 本章总结

网易微专业 犀牛学院 人工智能数学基础 Jason博士

## 本章参考资料

- Bishop, Christopher M. Pattern recognition and machine learning. springer, 2006.